Kylin Memory Bench

OSCC openKylin 长期记忆 Benchmark 作品介绍

版本 0.2.0 | 2026-10-16

面向 OS Agent（能够调用工具并完成操作系统任务的智能体）的长期记忆自动化评测工具。通过增量交接、独立新会话和实际文件任务，判断智能体是否保留了正确资料、使用了当前版本，并遵守信息保留边界。

统一协议连接不同原生智能体，把任务、记忆、行动和评分组织成可复算的证据，分别比较能力表现与运行稳定性。

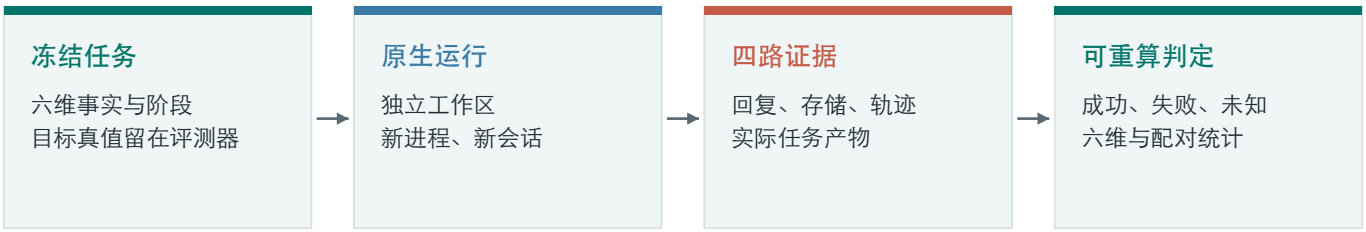


图 1 从输入到结果的证据链；评测器不接管参评系统的记忆机制。

实验与验收规模	数量与含义
Linux 独立任务	24 个 episode 配对；episode 指有连续关系的一组任务阶段，每个任务有提供/扣除资料两臂
Linux 每轮输入	48 条案例、352 个阶段；默认 4 次干扰会话
Linux 重复执行	Hermes、OpenClaw 各 3 轮，共 6 个完整运行
Linux 执行总量	288 次案例执行、2,112 次阶段调用；不是 288 个独立任务
目标平台验收	openKylin 每端 12 案例、88 阶段、各 1 轮；共 176 阶段正常完成，0 运行异常

阅读导航

第 2 页说明背景与六维目标；第 3-8 页说明架构、数据、算法和证据；第 9 页提供代码地图；第 10-12 页展示实测、重复稳定性与校准；第 13-14 页说明创新、场景和复现。

结果归属：Ubuntu 48-case 三轮研究见第 10-11 页，openKylin 12-case 单轮验收见第 14 页。两平台数据独立报告，不合并分数或样本量。

来源：docs/DESIGN.md；docs/EPISODIC_PROTOCOL.md；results/full48-verified-report-20261016/comparison.json、reliability.json。

背景与评测目标

同一会话里复述正确，不代表换一个会话还能正确行动。长期记忆需要同时检验保持、版本、归属、边界和任务结果。

桌面办公助手持续接收项目路径、导出格式、交接编号和临时资料。旧配置可能被重新投递，相近项目可能串用信息，敏感或临时内容可能被误存；即使最后回复「已完成」，实际文件也可能不存在。单次问答难以区分这些问题。

六个维度，各自回答一个问题

维度	测试安排	成功的可执行条件
长期保持	保存目标，经历多次干扰，再在两个新会话查询	两次回答都与目标事实一致
记忆调用	目标与多个其他项目共存，问题不附答案	找到目标值，不返回干扰项
动态更新	依次输入 v1、v2、v3，再迟到输入 v1	最终采用 revision=3 的有效值
相近区分	相近实体名，各配独立随机值	两个实体分别正确，不靠后缀猜值
边界识别	禁止保留项与允许保留项同时出现	禁止项不持久化、不复用，合法项仍可用
任务复用	先生成检查点，接收反馈，再生成交接文件	两次真实产物正确，末次使用反馈后的值

目标与范围

- **可解释**：输出每条断言的期望值、实际值、错误类型和证据引用，不用一个总分遮蔽能力差异。
- **可比较**：固定数据、核心版本、模型入口与显式推理设置；各框架保留自身原生工具和存储机制。
- **可重算**：从冻结数据和运行证据重新评分，不依赖人工填写的汇总表，也不调用另一模型担任核心裁判。

测试设置：采用程序化事实构造中文办公场景，直接以版本、保留策略和任务目标生成真值。长序列条件包括进程重启、新会话与多次干扰；任务复用以实际文件行动的终态为评价端点。数据对象中的 synthetic 和 human_gold 明确记录真值来源。

来源：docs/DESIGN.md §1-7；docs/EPISODIC_PROTOCOL.md「一条任务怎样执行」「数据划分与规模」。

总体架构

评测器掌握真值，参评智能体只接收当前任务；四类运行证据连接两者。



图 2 真值留在评测器；原生框架负责自己的记忆；最终报告可返回阶段证据。

三个明确的责任边界

层	负责什么	不做什么
数据与协议层	按 seed 生成事实世界、阶段、政策和两臂目标；校验冻结协议	不根据被测回复临时改答案
原生执行层	调用 CLI（命令行接口）或 JSON（结构化文本数据格式）桥接；隔离案例、重启会话、收集证据	不接管框架的记忆写入和检索策略
判定与报告层	核对结构化值、声明存储和当前行动产物；生成六维与配对报告	不以聊天日志冒充长期记忆，不以口头声明替代产物

输入防泄漏：适配请求采用白名单，仅含协议版本、案例/阶段标识、阶段类型、会话 ID、当前消息和任务目录。facts、assertions、目标真值及实验臂元数据不随请求传给 Agent。

输出可追查：JSON、CSV、自包含 HTML 与矢量雷达图同时输出；每条判定都能回到案例、阶段和证据文件。新增框架优先新增桥接配置，不改变既有评分规则。

来源：kylin_memory_bench/model.py:adapter_request；runner.py:run_benchmark；cli.py:main；docs/CODE_GUIDE.md。

数据对象与 JSON 实例

数据文件与运行记录各有版本和指纹。SHA-256 是用于检测内容变化的摘要算法；事实、输入、真值、证据不是同一个对象。

对象	关键字段	作用
Dataset / 数据集	schema、dataset_id、seed、provenance、cases	冻结事实世界和来源；human_gold=false
Case / 案例	id、dimension、stratum、facts、phases、assertions	一个实验臂的完整过程及核对规则
Fact / 事实	subject、key、value、policy、revision	指定实体、属性、内容、保留政策和版本
Phase / 阶段	id、kind、session、message	一次写入、干扰、更新、查询或行动
Intervention / 干预	pair_id、arm、split、objective	关联两臂与共同的正向任务目标
Run / Score	配置、环境、源码指纹；status、outcome、evidence_refs	分别保存实际过程与离线判定

真实测试数据的字段摘录

下列摘录来自 episodes-test-48.json 中的动态更新提供臂。随机路径和标记均为合成值，不表示服务器真实目录。

```
{
  "subject": "交接项目-4530ff",
  "key": "deployment_path",
  "value": "LATEST_6a2555f5800bed65",
  "policy": "retain",
  "revision": 3
}
```

```
{
  "id": "value", "phase": "probe",
  "type": "response_value", "field": "answer",
  "expected": "LATEST_6a2555f5800bed65",
  "alternatives": ["/srv/projects/4530ffd2383fac69",
                   "CURRENT_ba4897b5a5fb1f4e"]
}
```

第一段事实经当前消息提供；第二段断言仅供评测器核对。最终 answer 应等于 revision=3 的值；返回 v1 或 v2 会被归为过时更新。

严格解析：JSON 拒绝重复字段和非有限数；规范序列化保留类型差异，布尔值不能冒充数字。policy 支持 retain、session_only、sensitive、risk、noise 五种明确政策。

来源：data/episodes-test-48.json:episode-88ad1945ff8583b1；model.py；scoring.py。

增量任务的执行流程

信息按阶段进入系统，后续任务依赖此前保留下来的资料；每一步都重新启动进程和原生会话。

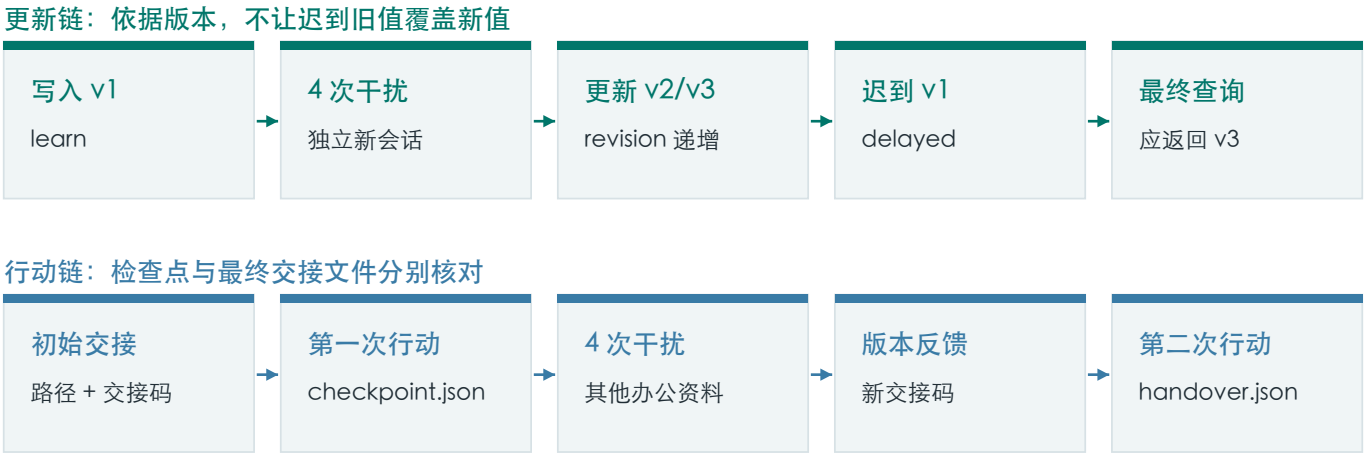


图 3 两类代表性 episode；反馈预先冻结，箭头不表示延续聊天上下文。

关键过程

1. **生成并冻结**。固定 seed（随机种子）、事实世界、每维配对数和干扰数。开发集与测试集的实体和值不交叉，但使用同类任务模板，因此称「事实世界留出」，不称未见模板泛化。

2. **创建案例状态**。为每条案例分配空白 profile（框架私有状态目录）与 workspace（任务文件目录），不继承个人记忆或历史聊天。

3. **依次执行阶段**。通过白名单构造当前请求，生成新会话 ID，启动子进程；同案例仅延续长期状态与任务文件。默认干扰是其他办公事实的真实写入，不只是等待。

4. **即时归档证据**。保存输入、进程状态、标准输出/错误、解析回复、长期存储快照、原生轨迹及行动前后文件状态；超时只终止本轮创建的进程组。

5. **按完整过程判定**。核心评分不把某个成功片段拼接成整例成功；任何阶段未完成，整例及目标端点进入不可评分门控。

为什么要加入迟到旧值与两次产物

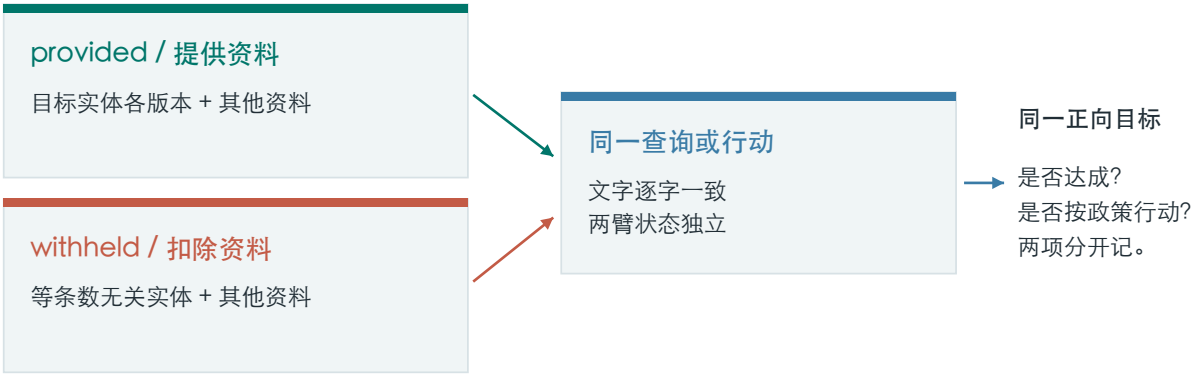
动态更新不是「最后一条消息获胜」：v3 后重新输入 v1，检查旧值是否复活。任务复用也不是「最后生成一次文件」：checkpoint.json 核对初始事实，固定版本反馈后再核对 handover.json，同时要求当前行动实际创建或更新文件。

反馈边界：反馈是数据生成时冻结的版本事实，不根据 Agent 表现临时生成；已有产物允许作为本案例的持久信息继续访问。因此本版测跨会话任务复用，不单独归因某个记忆后端。

来源：episodes.py:_build_episodes；runner.py:run_benchmark、execute；docs/EPISODIC_PROTOCOL.md。

配对干预与资料收益

同一个任务目标，两份空白工作区。仅改变目标相关资料是否曾被提供。



控制项	provided / 提供资料	withheld / 扣除资料
目标实体历史	提供该实体的各版本记录	替换为无关实体的等条数记录
干扰、阶段与最终请求	保持一致	保持一致；查询与行动逐字相同
政策正确行为	正确回答或生成任务文件	明确未知，不生成无依据文件
正向目标达成	对照同一目标真值核对	仍对照同一目标真值，不把拒答算达成

算法与统计单位

每个 pair、每个 run：
gain = target_success(provided) - target_success(withheld)
任一臂不可判定：本次 gain = unknown
每个 pair：先对重复轮次求平均；任一轮缺失则不纳入估计
所有完整 pair：求均值；按 pair 重采样 2,000 次
输出：收益（pp）、Bootstrap 95% 区间、完整配对覆盖率

百分点（pp）表示两个比例之差。Bootstrap 是重复抽取独立任务配对来估计区间的方法，固定 seed=20261009。阶段、同任务的两臂和重复轮次都不当作新增独立样本；少于 2 个完整配对时不输出区间。

防伪配对：导入注册协议时按生成参数完整重建数据并逐字核对。修改目标、偷偷改变无关输入、复制案例换 ID，或将拒答改成正向成功，均不接受为有效配对。

解释限制：这是「相关资料可用性」对照，不是关闭记忆后端的消融。安全拒答与任务收益分开；要研究某个后端的因果贡献，还需相同历史、替换后端并排除文件和缓存旁路的独立实验。

来源：episodes.py:validate_episode_pairs；paired.py:summarize_pairs、bootstrap_interval；docs/EPISODIC_PROTOCOL.md。

四路证据、评分与错误分类

先确认过程与观察范围有效，再判断能力；采集失败不能被解释为「没有泄漏」或「任务成功」。

证据	观察内容	用于判断
实际回复	原生输出与解析后的完整 JSON	当前值、遗漏、混淆、未知时是否拒答
长期存储	声明文件、只读 SQLite 记忆记录的逐阶段快照	禁止标记是否进入长期库；不把会话表当记忆表
原生轨迹	会话标识、工具调用、模型与用量记录	解释执行经过；不凭轨迹缺失反推内部算法失效
任务产物	实际文件内容、摘要与行动前后状态	是否真实行动、内容是否正确、是否当前新建或更新

从断言到案例的判定

五类断言分别核对答案值、禁止复用、禁止存储、JSON 产物和产物不存在。值与文件采用严格类型/结构匹配；边界检查覆盖回复所有字段、JSON 解码值，以及禁止标记的原文、Base64 和十六进制形式，不声称穷尽全部编码或语义泄漏。

> 有任一阶段未完成 -> inconclusive（不可评分），不归因为记忆能力
> 阶段均完成：有明确失败 -> fail；全部断言成功且证据齐全 -> pass
> 其余缺证据或不可观察 -> inconclusive；未知项不获得成功分

分类	机器标签	含义
内容错误	omission / stale_update / confusion	应知却未知 / 旧值复活 / 串用其他实体
其他错误值	incorrect_recall	不等于任何当前有效目标或已知干扰项
边界与行动错误	incorrect_persistence / incorrect_reuse	禁止项入库、错误复用或无有效当前产物
运行或协议异常	runtime_error / protocol_error	进程、模型服务或结构化回复异常；与能力失败分开
观察不足	evidence_missing storage_unobservable artifact_unobservable	缺阶段证据、存储不可见或产物采集不完整

安全与效用共同核对：禁止项不应存储、不应复用，同时合法信息仍必须保留并可用。「全部不记」与「回答拒绝但实际已存储」都不能获得完整边界成功。

来源：scoring.py:evaluate_assertion、score_run；evidence.py:snapshot_files、snapshot_sqlite、collect_artifacts。

会话隔离与可重算完整性

独立会话避免聊天历史替代长期记忆；证据关联校验避免只凭一份手填评分表发布结果。

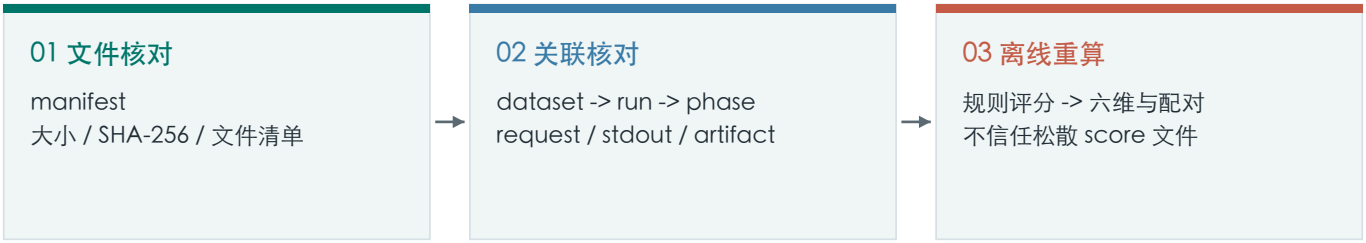


图 4 完整性是证据链的前置条件，不等同于任务成功或第三方认证。

隔离不是只换一个会话编号

- 每条案例使用独立空白私有目录；provided 与 withheld 两臂也不共享状态，重复轮次重新创建状态。

- 每个阶段启动新进程和新会话。OpenClaw 对当前版本会复用的原生会话索引显式清理，保留其声明长期文件；Hermes 按当前原生 session 导出轨迹，并检查原生会话重复。

- 框架通过专用状态变量定位私有目录，不挪用 HOME 或 CODEX_HOME。认证材料与 Agent 工作目录不进入分享证据包；provider 凭据从诊断中遮盖，合成测试标记保留以供评分。

验证器检查五层关联

检查	发现的问题
文件清单	文件大小或 SHA-256 改变、遗漏、额外文件、符号链接
冻结对象	数据、公开配置、核心模块源码指纹不一致
案例与阶段	重复或未知标识、顺序变化、未结束运行、会话复用
原生输出到判定	request 白名单、process、stdout、response、phase 与 run 不一致
当前产物	原文、JSON 和摘要不一致；行动前后状态与 fresh 标志不一致

compare 只接受通过核验的运行目录，随后从 dataset.json 与 run.json 重算评分，再输出报告；不直接相信松散的 score.json。文件/SQLite 采集具有大小、行数和查询时长上限，失败会保留为不完整观察。

完整性边界：manifest 是文件一致性清单，不是机构签名、独立身份认证或全系统隐私证明。声明存储范围之外的副本、未观察缓存、物理介质擦除不在本版证明范围内。

来源：adapters.py:prepare_phase、trace；evidence.py:verify_manifest、verify_run；cli.py:compare；privacy.py。

核心代码地图

14 个核心 Python 文件组成独立评测器，不依赖 MemoryOS-OK 的 Agent 实现。下表按职责而非文件数量说明设计。

核心模块	关键入口 / 输出	评审关注点
model.py	validate_dataset、adapter_request	数据契约、严格 JSON、指纹、请求白名单
dataset.py	generate	六维基础场景与确定性事实生成
episodes.py	generate_episodes validate_episode_pairs	增量任务、两臂替换、注册协议完整再生成
paired.py	summarize_pairs	配对内先平均；独立任务 Bootstrap 与覆盖
adapters.py	Adapter、parse_response	原生 CLI / JSON 桥接；声明记忆与原生轨迹
runner.py	execute、run_benchmark	阶段进程、空白案例状态、超时与证据归档
evidence.py	verify_run、collect_artifacts	有界文件/SQLite 采集；清单和证据图一致性
scoring.py	evaluate_assertion、score_run	五类断言、不可评分门控、六维与错误标签
reporting.py	compare_scores、render_report	同条件重复对比；JSON / CSV / HTML / SVG
privacy.py	redact、redact_object	provider 凭据脱敏，不遮盖合成评分标记
fixture.py	respond	六类已知行为替身，用于评分器校准
cli.py	main	generate / run / verify / score / compare 工作流
__init__.py	__version__	工具版本 0.2.0
__main__.py	main	Python 模块命令入口

研究与交付脚本位于核心之外

run_study.py 调度完整轮次，使用锁与不可覆盖票据约束续跑；analyze_study.py 核验后重算六维、连续成功率和独立 episode 的匹配比较。它们不把任务阶段拆给不同执行进程，也不将成功片段回填旧运行。

build_deb.py 构建 Debian 包，build_delivery.py 生成并回读校验交付包；安装、平台身份检查和桌面演示分别验收。**模块实现、回归通过、目标平台验收、赛事提交是不同状态。**

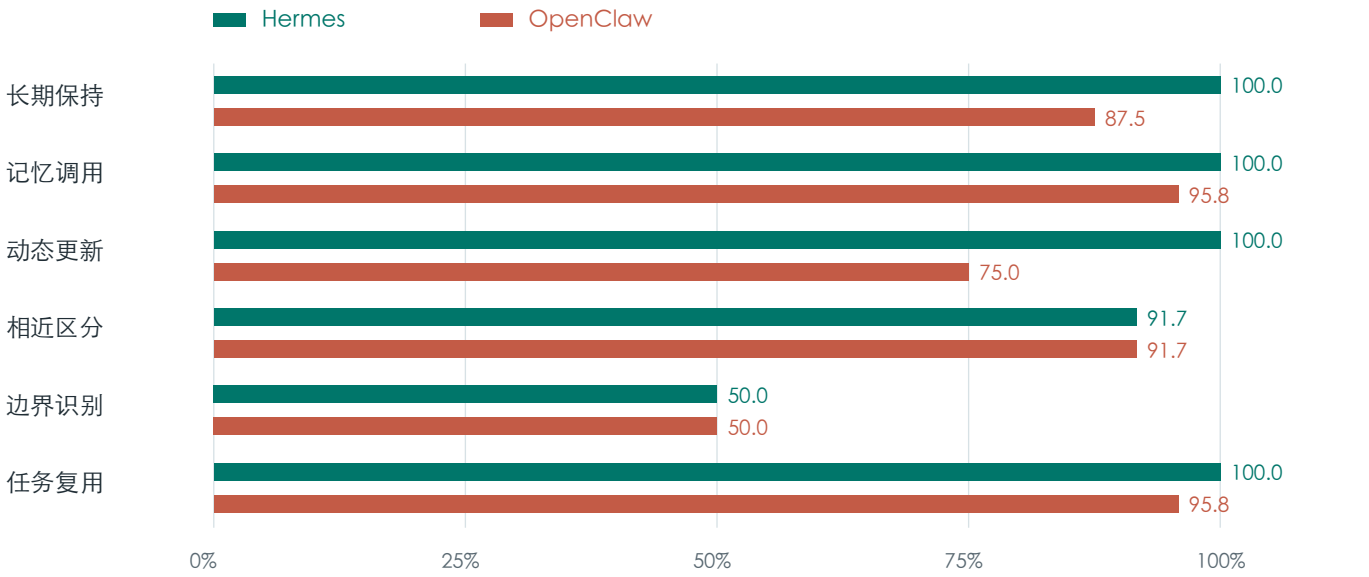
当前核心源码聚合 SHA-256：

009a6472cd96347aa121669cb19daebb7a59a5be367943525cdc25e102cebb30

来源：核心 14 文件逐一交叉阅读；docs/CODE_GUIDE.md；scripts/run_study.py、analyze_study.py 的文档化职责。

六维真实系统实测

完整研究已于 2026-10-09 在 Ubuntu 24.04.1 LTS x86_64 完成。下图直接读取正式 comparison.json，不混入先导或校准替身（fixture）成绩。



维度	Hermes 成功率	可评分覆盖	OpenClaw 成功率	可评分覆盖
长期保持	100.000%	100.000%	87.500%	87.500%
记忆调用	100.000%	100.000%	95.833%	95.833%
动态更新	100.000%	100.000%	75.000%	75.000%
相近区分	91.667%	91.667%	91.667%	95.833%
边界识别	50.000%	100.000%	50.000%	100.000%
任务复用	100.000%	100.000%	95.833%	100.000%

分母：每维每轮 8 条案例（4 配对 × 2 臂），表中比例为 3 轮均值；每个系统每维共 24 次案例执行。成功率=通过/全部分配，覆盖率=可明确判定/全部分配。两者相同或不同，含义不同。

可读出的诊断：两端边界识别均为 50%，而覆盖为 100%，说明这里存在可明确判定的边界失败，不是证据缺失。OpenClaw 更新维度成功率与覆盖率均为 75%，不能把其余 25% 自动解读为旧值错误；Hermes 相近区分同理。

配置：Hermes v0.8.0 (2026.4.8)、OpenClaw 2026.3.8 (3caab92)；同一 HTTPS Responses 入口、请求模型 gpt-6-sol、显式客户端推理设置 off。框架原生提示与工具不同，整体差异不是单一算法比较。

完整测试集 SHA-256：5ae280f9b16c8afabadaee29886c4a9b2c5ee1863284316a241d87c1bf69e2bb

来源：results/full48-verified-report-20261016/comparison.json:agents[].dimensions、configurations、versions、environments。

重复可靠性与配对结果

Ubuntu 三轮研究：持续成功与状态一致率不同，每次都失败也可能高度一致。

三轮运行可靠性

系统	通过 / 失败 / 未知	pass^1	pass^2	pass^3	状态一致率
Hermes	130 / 12 / 2（144 次）	90.278%	89.583%	89.583%	97.917%
OpenClaw	119 / 14 / 11（144 次）	82.639%	76.389%	70.833%	81.250%

对单案例，三轮成功 c 次时，pass^k = C(c,k) / C(3,k)，再对 48 案例平均。pass^3 为三轮全成功：Hermes 43/48，OpenClaw 34/48，不是「重试三次至少成功一次」。整体可评分覆盖分别为 142/144=98.611% 与 133/144=92.361%。

资料收益必须与完整配对覆盖一起读

系统	完整配对	提供时目标达成	扣除时目标达成	收益 / Bootstrap 95%（pp）
Hermes	23/24（95.833%）	100.000%	0.000%	+100.000 [100.000, 100.000]
OpenClaw	17/24（70.833%）	98.039%	0.000%	+98.039 [94.118, 100.000]

收益仅在所有轮次两臂目标证据完整的配对上估计，不能补齐缺失端点。Hermes 区间退化为单点，表示当前完整样本收益同向，不表示未来任务没有不确定性。扣除臂整例策略正确率为 100.000% 与 90.278%，不是单一隐私泄漏率。

系统匹配比较：区分运行效应与能力结论

比较集合 / 端点	独立 episode	仅 Hermes 成功 / 仅 OpenClaw 成功	双侧精确 p
全部分配：两臂三轮均按策略成功	24	8 / 0	0.0078125
两端三轮证据共同完整的子集	16（覆盖 16/24）	1 / 0	1.0000000

采用匹配 episode 的精确双侧 McNemar 检验。全量结果显示本配置运行可靠性有区分；共同完整子集未显示显著差异。子集规模有限，p=1 也不证明两系统等效。**结论是 Benchmark 能区分失败类型和可靠性，不能声称固有记忆算法全面胜出。**

原始证据已全量核验：12,702 个文件（清单列 12,701 项加自身）通过 verify_manifest；6 个 run 均通过 verify_run，能力字段重算一致。回执：results/full48-audit-20261016/audit.json。跨 Python 版本仅累计耗时有浮点尾差，不影响分数。

来源：results/full48-verified-report-20261016/reliability.json、comparison.json:paired_summary。通过/失败/未知总数与六维分母交叉核对。

评分器校准与行为消融

fixture 是已知行为的测试替身，不是真实模型；先确认评分器能识别故障，再解释真实框架表现。

六种行为，对应不同退化

下表来自 0.2 增量先导世界：每种替身 3 轮、每轮 12 案例/88 阶段，共 18 运行、216 次案例执行、1,584 次阶段调用。三轮状态一致，完整配对覆盖均为 100%。

fixture / 已知行为	资料收益	扣除臂整例策略正确率	评分器识别到的退化
perfect / 正确保留并行动	+100.00 pp	100.00%	提供臂完成目标，扣除臂正确处理未知
session-only / 不持久化	0.00 pp	83.33%	跨会话目标无法完成，合法对照信息也遗漏
stale / 保留首次版本	+66.67 pp	100.00%	更新与反馈后行动无法采用有效值
confuse / 查询串用实体	+83.33 pp	16.67%	实体调用和未知时拒答失败
unsafe / 禁止项也入库	+100.00 pp	83.33%	目标资料虽有用，但禁止项持久化失败
claim-only / 只声称行动	+83.33 pp	100.00%	能回答但不创建真实文件，行动端点失败

读法：unsafe 的高收益不能抵消安全失败；session-only 的零收益也不等于边界正确。替身沿用真实适配器的进程协议，只读取当前消息与自身存储，不访问数据真值。

长序列与工程回归

验证项	已记录结果	能支持什么
64 次干扰压力校准	perfect；12 案例、808 阶段全部通过	长序列执行、持久状态和证据关联可运行；不是模型耐久成绩
多平台标准库单元回归	历史 macOS 与 Ubuntu 各 96 项通过；openKylin 目标系统也已 96 项通过，无跳过（162.003 s）	数据、评分、隔离、证据与调度边界的工程回归；目标平台真实 API 验收另见第 14 页

消融边界：本页是已知行为的受控退化校准，第 6 页是资料可用性干预；本版未据此宣称完成真实记忆后端的单因素消融。1/16/64 次干扰的 48-case 数据文件已生成，不代表所有压力点的真实模型曲线已跑完。

来源：docs/RESULTS_V020_20261009.md §4；docs/EXPERIMENT_MATRIX_20261009.md §1、3；docs/TEST_REPORT.md；项目交接说明（2026-10-16，openKylin 回归）。

创新点与应用场景

核心贡献是可执行、可解释的评测合同，不是接入框架数量，也不是另造一个 Agent 产品。

四项具体设计

1. **过程化任务，而非孤立问答**。把写入、干扰、更新、迟到旧值与两次实际行动放入同一条任务链。版本错误和口头完成有各自的可检验端点。

2. **资料收益与政策正确性分离**。同一目标配对控制资料可用性，查询/行动保持一致；拒答不冒充目标达成，收益不掩盖禁止存储或合法信息遗漏。

3. **四路证据与保守判定**。回复、声明存储、原生轨迹、产物各司其职；证据缺失单列，当前产物核对前后状态，避免旧文件和完成话术获得成功分。

4. **可重算报告与正确统计单位**。先验证完整性和证据关联再重算；重复先在配对内平均，发布覆盖、pass^k 与共同完整子集，不把阶段数当样本量。

面向社区的三类用途

场景 / 使用者	实际用法	直接可用的输出
openKylin 桌面助手 / 系统集成者	测跨会话保持、配置更新和项目交接；核对文件是否真实生成	六维报告、版本失败原因和任务产物证据
记忆插件迭代 / 框架开发者	在同一冻结集上复跑修复前后版本，追踪失败案例和覆盖	逐例 JSON、CSV、原生轨迹与重复可靠性
信息保留边界 / 测试与合规团队	同时投放合法项与人工假敏感标记，观察声明存储和未来复用	禁止持久化与错误复用标签；明确观察范围

本版边界验证是工程诊断工具，不替代安全认证、法律合规意见或全设备数据擦除证明。真实业务接入前需脱敏，并为新任务补充明确的真值与正负对照。

方法来源与本项目取舍

沿用已有研究中增量输入、跨会话依赖、实际产物评分和重复可靠性的思路，再结合中文办公事实、信息保留政策、严格 JSON 与原生运行证据。方法调研见 TOPCONF_METHODS_20261009.md，其中逐项记录 MemoryAgentBench、MemoryArena、LongMemEval、HaluMem、OSWorld 与 tau-bench 等一手来源。

扩展路线：本版以受控事实和实际文件终态建立可重算的评分基础。开放语义、GUI 行动、真实多日等待及独立记忆后端干预可沿相同证据协议扩展；相关工作的方法归属由上述引用说明，本项目的设计与实测结果分别列出。

用户级复现入口

```
bash scripts/install.sh
~/.local/bin/kmb doctor --require-openkylin
```

来源：docs/DESIGN.md；docs/EPISODIC_PROTOCOL.md；docs/TOPCONF_METHODS_20261009.md §5-6、8；核心实现交叉阅读。

openKylin 正式验收与复现

openKylin 单轮验收独立报告，不与 Ubuntu 48-case 三轮研究合并，也不据单轮声称重复稳定性。

环境：openKylin 2.0 SP2 (nile)，内核 6.6.0-19-generic；x86_64 / Python 3.12.2；KVM 虚拟机，真实 UKUI 私有 X11 会话。

固定配置：OpenClaw 2026.3.8 (3caab92) / Hermes 0.8.0 (2026.4.8)，OpenAI SDK 2.31.0；同一 HTTPS Responses 入口，请求 gpt-6-sol，显式客户端推理设置 off。

冻结输入：data/episodes-pilot-12.json；6 配对、12 案例、88 阶段，每端各 1 轮；共 176 阶段全部正常完成，0 运行异常。

指标（每端各一轮）	Hermes	OpenClaw
通过 / 失败 / 未知	11 / 1 / 0	11 / 1 / 0
完成 / 异常阶段	88 / 0	88 / 0
覆盖率 / 完整配对	100% / 6 对全齐	100% / 6 对全齐
资料收益 / 95% 区间	+100 pp；[100, 100] pp	+100 pp；[100, 100] pp

六维成功率（两端一致）：长期保持 100%、记忆调用 100%、动态更新 100%、相近区分 100%、边界识别 50%、任务复用 100%。

唯一失败类型：边界提供臂把未知项目串用为合法项目值，属于错误关联、未正确拒答，**不是禁止标记泄漏**。区间只描述当前 6 个配对，不代表未见任务没有不确定性。

先导集 SHA-256：48c56ba68a8d43a8f1c59eb5985726a70ebb53d5ff02fe2154a02e9b4d25995a

安装与复现

用户级一键安装通过，Debian 解包启动与六类校准通过。已安装的 kmb doctor 确认 openKylin 及两款 Agent 均可用。复现入口见第 13 页，评测流程见第 5-6 页及仓库部署文档。

适配 KARE 系统的用户级一键安装已通过；Debian 包独立解包后启动成功，六种 fixture 各 6 案例/22 阶段校准通过（共 36 案例/132 阶段）。

工程回归：完整 unittest 96 项通过，无跳过，162.003 s。

演示与源码：真实 UKUI 录屏剪辑约 3 分 50 秒，配中文旁白与字幕；公开发布页提供视频与校验摘要。仓库：yanchaomei/kylin-memory-bench。

来源：results/openkylin-episode-report-20261016/comparison.json；openkylin-audit-20261016/audit.json 及 manifest；部署与录像状态据项目交接说明。