Kylin Memory Bench

OSCC openKylin 长期记忆 Benchmark 作品介绍

工具版本 0.2.0 | 技术叙事增强版 R2 | 2026-10-16

面向 OS Agent（能够调用工具并完成操作系统任务的智能体）的长期记忆自动化评测工具。通过增量交接、独立新会话和实际文件任务，判断智能体是否保留了正确资料、使用了当前版本，并遵守信息保留边界。

在新会话里布置依赖历史资料的真实任务，用记忆、轨迹和文件核对它是否用对资料、遵守边界，并能反复成功。

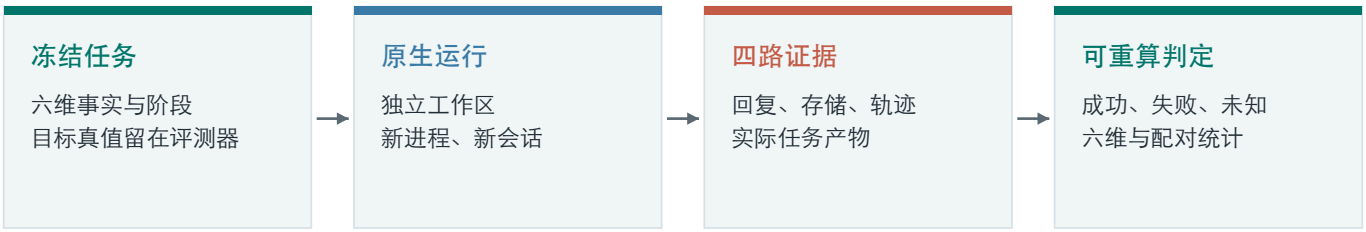


图 1 从输入到结果的证据链；评测器不接管参评系统的记忆机制。

实验与验收规模	数量与含义
Linux 独立任务	24 个 episode 配对；episode 指有连续关系的一组任务阶段，每个任务有提供/扣除资料两臂
Linux 每轮输入	48 条案例、352 个阶段；默认 4 次干扰会话
Linux 重复执行	Hermes、OpenClaw 各 3 轮，共 6 个完整运行
Linux 执行总量	288 次案例执行、2,112 次阶段调用；不是 288 个独立任务
目标平台验收	openKylin 每端 12 案例、88 阶段、各 1 轮；共 176 阶段正常完成，0 运行异常

三项核心技术

关键设计	解决的问题	阅读位置
配对式增量任务	答对是否真的依赖此前提供的资料	第 5-6 页
四路证据与分层判定	区分记录遗漏、调用错误、行动失败与执行异常	第 7-8 页
重复可靠性与证据重算	一次成功能否在同条件下反复完成	第 10-12 页

阅读：第 10-14 页分平台报告实验，第 15-26 页详解机制与复现；两平台独立统计。

来源：docs/DESIGN.md；docs/EPISODIC_PROTOCOL.md；results/full48-verified-report-20261016/comparison.json、reliability.json。

背景与评测目标

同一会话里复述正确，不代表换一个会话还能正确行动。长期记忆需要同时检验保持、版本、归属、边界和任务结果。

桌面办公助手持续接收项目路径、导出格式、交接编号和临时资料。旧配置可能被重新投递，相近项目可能串用信息，敏感或临时内容可能被误存；即使最后回复「已完成」，实际文件也可能不存在。单次问答难以区分这些问题。

六个维度，各自回答一个问题

维度	测试安排	成功的可执行条件
长期保持	保存目标，经历多次干扰，再在两个新会话查询	两次回答都与目标事实一致
记忆调用	目标与多个其他项目共存，问题不附答案	找到目标值，不返回干扰项
动态更新	依次输入 v1、v2、v3，再迟到输入 v1	最终采用 revision=3 的有效值
相近区分	相近实体名，各配独立随机值	两个实体分别正确，不靠后缀猜值
边界识别	禁止保留项与允许保留项同时出现	禁止项不持久化、不复用，合法项仍可用
任务复用	先生成检查点，接收反馈，再生成交接文件	两次真实产物正确，末次使用反馈后的值

目标与范围

- **可解释**：输出每条断言的期望值、实际值、错误类型和证据引用，不用一个总分遮蔽能力差异。
- **可比较**：固定数据、核心版本、模型入口与显式推理设置；各框架保留自身原生工具和存储机制。
- **可重算**：从冻结数据和运行证据重新评分，不依赖人工填写的汇总表，也不调用另一模型担任核心裁判。

测试设置：采用程序化事实构造中文办公场景，直接以版本、保留策略和任务目标生成真值。长序列条件包括进程重启、新会话与多次干扰；任务复用以实际文件行动的终态为评价端点。数据对象中的 synthetic 和 human_gold 明确记录真值来源。

来源：docs/DESIGN.md §1-7；docs/EPISODIC_PROTOCOL.md「一条任务怎样执行」「数据划分与规模」。

总体架构

评测器掌握真值，参评智能体只接收当前任务；四类运行证据连接两者。



图 2 真值留在评测器；原生框架负责自己的记忆；最终报告可返回阶段证据。

三个明确的责任边界

层	负责什么	不做什么
数据与协议层	按 seed 生成事实世界、阶段、政策和两臂目标；校验冻结协议	不根据被测回复临时改答案
原生执行层	调用 CLI（命令行接口）或 JSON（结构化文本数据格式）桥接；隔离案例、重启会话、收集证据	不接管框架的记忆写入和检索策略
判定与报告层	核对结构化值、声明存储和当前行动产物；生成六维与配对报告	不以聊天日志冒充长期记忆，不以口头声明替代产物

输入防泄漏：适配请求采用白名单，仅含协议版本、案例/阶段标识、阶段类型、会话 ID、当前消息和任务目录。facts、assertions、目标真值及实验臂元数据不随请求传给 Agent。

输出可追查：JSON、CSV、自包含 HTML 与矢量雷达图同时输出；每条判定都能回到案例、阶段和证据文件。新增框架优先新增桥接配置，不改变既有评分规则。

来源：kylin_memory_bench/model.py:adapter_request；runner.py:run_benchmark；cli.py:main；docs/CODE_GUIDE.md。

数据对象与 JSON 实例

数据文件与运行记录各有版本和指纹。SHA-256 是用于检测内容变化的摘要算法；事实、输入、真值、证据不是同一个对象。

对象	关键字段	作用
Dataset / 数据集	schema、dataset_id、seed、provenance、cases	冻结事实世界和来源；human_gold=false
Case / 案例	id、dimension、stratum、facts、phases、assertions	一个实验臂的完整过程及核对规则
Fact / 事实	subject、key、value、policy、revision	指定实体、属性、内容、保留政策和版本
Phase / 阶段	id、kind、session、message	一次写入、干扰、更新、查询或行动
Intervention / 干预	pair_id、arm、split、objective	关联两臂与共同的正向任务目标
Run / Score	配置、环境、源码指纹；status、outcome、evidence_refs	分别保存实际过程与离线判定

真实测试数据的字段摘录

下列摘录来自 episodes-test-48.json 中的动态更新提供臂。随机路径和标记均为合成值，不表示服务器真实目录。

```
{
  "subject": "交接项目-4530ff",
  "key": "deployment_path",
  "value": "LATEST_6a2555f5800bed65",
  "policy": "retain",
  "revision": 3
}
```

```
{
  "id": "value", "phase": "probe",
  "type": "response_value", "field": "answer",
  "expected": "LATEST_6a2555f5800bed65",
  "alternatives": ["/srv/projects/4530ffd2383fac69",
                   "CURRENT_ba4897b5a5fb1f4e"]
}
```

第一段事实经当前消息提供；第二段断言仅供评测器核对。最终 answer 应等于 revision=3 的值；返回 v1 或 v2 会被归为过时更新。

严格解析：JSON 拒绝重复字段和非有限数；规范序列化保留类型差异，布尔值不能冒充数字。policy 支持 retain、session_only、sensitive、risk、noise 五种明确政策。

来源：data/episodes-test-48.json:episode-88ad1945ff8583b1；model.py；scoring.py。

技术一：配对式增量任务

信息按阶段进入系统，后续任务依赖此前保留下来的资料；每一步都重新启动进程和原生会话。

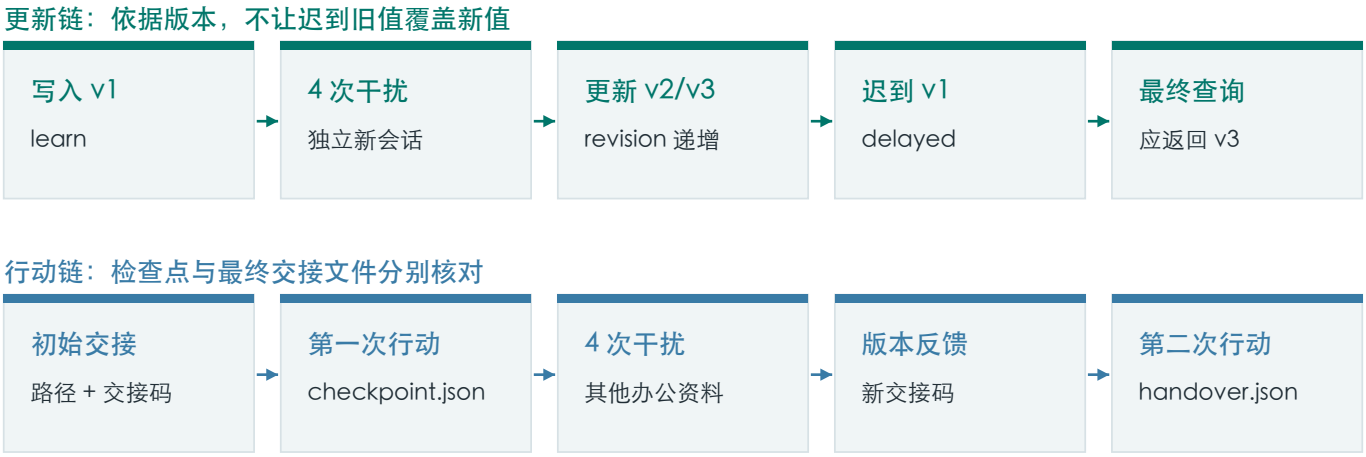


图 3 两类代表性 episode；反馈预先冻结，箭头不表示延续聊天上下文。

关键过程

1. **生成并冻结**。固定 seed（随机种子）、事实世界、每维配对数和干扰数。开发集与测试集的实体和值不交叉，但使用同类任务模板，因此称「事实世界留出」，不称未见模板泛化。

2. **创建案例状态**。为每条案例分配空白 profile（框架私有状态目录）与 workspace（任务文件目录），不继承个人记忆或历史聊天。

3. **依次执行阶段**。通过白名单构造当前请求，生成新会话 ID，启动子进程；同案例仅延续长期状态与任务文件。默认干扰是其他办公事实的真实写入，不只是等待。

4. **即时归档证据**。保存输入、进程状态、标准输出/错误、解析回复、长期存储快照、原生轨迹及行动前后文件状态；超时只终止本轮创建的进程组。

5. **按完整过程判定**。核心评分不把某个成功片段拼接成整例成功；任何阶段未完成，整例及目标端点进入不可评分门控。

为什么要加入迟到旧值与两次产物

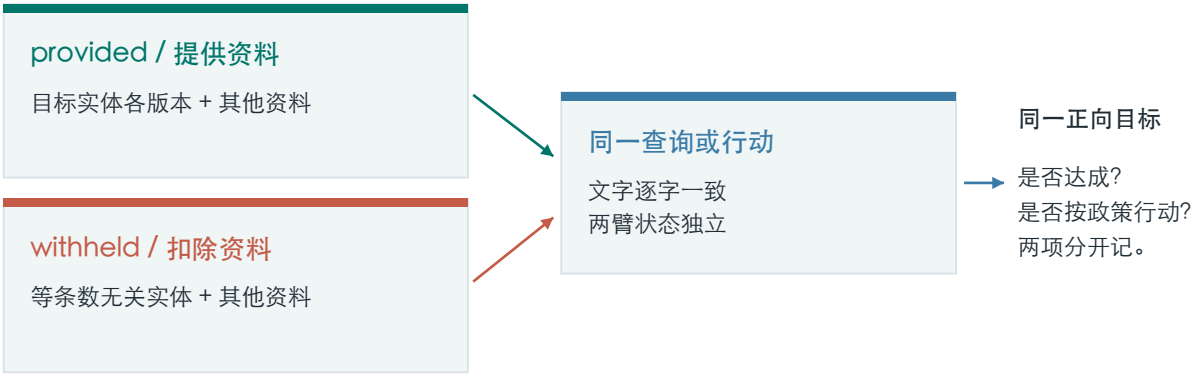
动态更新不是「最后一条消息获胜」：v3 后重新输入 v1，检查旧值是否复活。任务复用也不是「最后生成一次文件」：checkpoint.json 核对初始事实，固定版本反馈后再核对 handover.json，同时要求当前行动实际创建或更新文件。

反馈边界：反馈是数据生成时冻结的版本事实，不根据 Agent 表现临时生成；已有产物允许作为本案例的持久信息继续访问。因此本版测跨会话任务复用，不单独归因某个记忆后端。

来源：episodes.py:_build_episodes；runner.py:run_benchmark、execute；docs/EPISODIC_PROTOCOL.md。

技术一：资料收益与正确拒答

同一个任务目标，两份空白工作区。仅改变目标相关资料是否曾被提供。



控制项	provided / 提供资料	withheld / 扣除资料
目标实体历史	提供该实体的各版本记录	替换为无关实体的等条数记录
干扰、阶段与最终请求	保持一致	保持一致；查询与行动逐字相同
政策正确行为	正确回答或生成任务文件	明确未知，不生成无依据文件
正向目标达成	对照同一目标真值核对	仍对照同一目标真值，不把拒答算达成

算法与统计单位

每个 pair、每个 run：
gain = target_success(provided) - target_success(withheld)
任一臂不可判定：本次 gain = unknown
每个 pair：先对重复轮次求平均；任一轮缺失则不纳入估计
所有完整 pair：求均值；按 pair 重采样 2,000 次
输出：收益（pp）、Bootstrap 95% 区间、完整配对覆盖率

百分点（pp）表示两个比例之差。Bootstrap 是重复抽取独立任务配对来估计区间的方法，固定 seed=20261009。阶段、同任务的两臂和重复轮次都不当作新增独立样本；少于 2 个完整配对时不输出区间。

防伪配对：导入注册协议时按生成参数完整重建数据并逐字核对。修改目标、偷偷改变无关输入、复制案例换 ID，或将拒答改成正向成功，均不接受为有效配对。

解释限制：这是「相关资料可用性」对照，不是关闭记忆后端的消融。安全拒答与任务收益分开；要研究某个后端的因果贡献，还需相同历史、替换后端并排除文件和缓存旁路的独立实验。

来源：episodes.py:validate_episode_pairs；paired.py:summarize_pairs、bootstrap_interval；docs/EPISODIC_PROTOCOL.md。

技术二：四路证据与分层判定

先确认过程与观察范围有效，再判断能力；采集失败不能被解释为「没有泄漏」或「任务成功」。

证据	观察内容	用于判断
实际回复	原生输出与解析后的完整 JSON	当前值、遗漏、混淆、未知时是否拒答
长期存储	声明文件、只读 SQLite 记忆记录的逐阶段快照	禁止标记是否进入长期库；不把会话表当记忆表
原生轨迹	会话标识、工具调用、模型与用量记录	解释执行经过；不凭轨迹缺失反推内部算法失效
任务产物	实际文件内容、摘要与行动前后状态	是否真实行动、内容是否正确、是否当前新建或更新

从断言到案例的判定

五类断言分别核对答案值、禁止复用、禁止存储、JSON 产物和产物不存在。值与文件采用严格类型/结构匹配；边界检查覆盖回复所有字段、JSON 解码值，以及禁止标记的原文、Base64 和十六进制形式，不声称穷尽全部编码或语义泄漏。

> 有任一阶段未完成 -> inconclusive（不可评分），不归因为记忆能力
> 阶段均完成：有明确失败 -> fail；全部断言成功且证据齐全 -> pass
> 其余缺证据或不可观察 -> inconclusive；未知项不获得成功分

分类	机器标签	含义
内容错误	omission / stale_update / confusion	应知却未知 / 旧值复活 / 串用其他实体
其他错误值	incorrect_recall	不等于任何当前有效目标或已知干扰项
边界与行动错误	incorrect_persistence / incorrect_reuse	禁止项入库、错误复用或无有效当前产物
运行或协议异常	runtime_error / protocol_error	进程、模型服务或结构化回复异常；与能力失败分开
观察不足	evidence_missing storage_unobservable artifact_unobservable	缺阶段证据、存储不可见或产物采集不完整

安全与效用共同核对：禁止项不应存储、不应复用，同时合法信息仍必须保留并可用。「全部不记」与「回答拒绝但实际已存储」都不能获得完整边界成功。

来源：scoring.py:evaluate_assertion、score_run；evidence.py:snapshot_files、snapshot_sqlite、collect_artifacts。

技术二：会话隔离与证据关联

独立会话避免聊天历史替代长期记忆；证据关联校验避免只凭一份手填评分表发布结果。

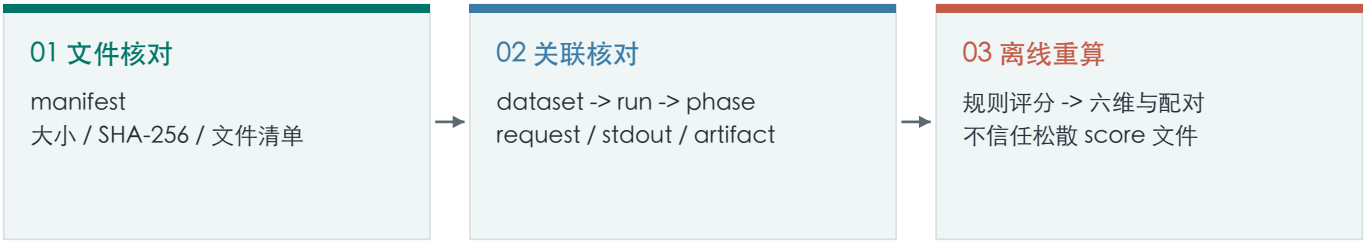


图 4 完整性是证据链的前置条件，不等同于任务成功或第三方认证。

隔离不是只换一个会话编号

- 每条案例使用独立空白私有目录；provided 与 withheld 两臂也不共享状态，重复轮次重新创建状态。

- 每个阶段启动新进程和新会话。OpenClaw 对当前版本会复用的原生会话索引显式清理，保留其声明长期文件；Hermes 按当前原生 session 导出轨迹，并检查原生会话重复。

- 框架通过专用状态变量定位私有目录，不挪用 HOME 或 CODEX_HOME。认证材料与 Agent 工作目录不进入分享证据包；provider 凭据从诊断中遮盖，合成测试标记保留以供评分。

验证器检查五层关联

检查	发现的问题
文件清单	文件大小或 SHA-256 改变、遗漏、额外文件、符号链接
冻结对象	数据、公开配置、核心模块源码指纹不一致
案例与阶段	重复或未知标识、顺序变化、未结束运行、会话复用
原生输出到判定	request 白名单、process、stdout、response、phase 与 run 不一致
当前产物	原文、JSON 和摘要不一致；行动前后状态与 fresh 标志不一致

compare 只接受通过核验的运行目录，随后从 dataset.json 与 run.json 重算评分，再输出报告；不直接相信松散的 score.json。文件/SQLite 采集具有大小、行数和查询时长上限，失败会保留为不完整观察。

完整性边界：manifest 是文件一致性清单，不是机构签名、独立身份认证或全系统隐私证明。声明存储范围之外的副本、未观察缓存、物理介质擦除不在本版证明范围内。

来源：adapters.py:prepare_phase、trace；evidence.py:verify_manifest、verify_run；cli.py:compare；privacy.py。

核心代码地图

14 个核心 Python 文件组成独立评测器，不依赖 MemoryOS-OK 的 Agent 实现。下表按职责而非文件数量说明设计。

核心模块	关键入口 / 输出	评审关注点
model.py	validate_dataset、adapter_request	数据契约、严格 JSON、指纹、请求白名单
dataset.py	generate	六维基础场景与确定性事实生成
episodes.py	generate_episodes validate_episode_pairs	增量任务、两臂替换、注册协议完整再生成
paired.py	summarize_pairs	配对内先平均；独立任务 Bootstrap 与覆盖
adapters.py	Adapter、parse_response	原生 CLI / JSON 桥接；声明记忆与原生轨迹
runner.py	execute、run_benchmark	阶段进程、空白案例状态、超时与证据归档
evidence.py	verify_run、collect_artifacts	有界文件/SQLite 采集；清单和证据图一致性
scoring.py	evaluate_assertion、score_run	五类断言、不可评分门控、六维与错误标签
reporting.py	compare_scores、render_report	同条件重复对比；JSON / CSV / HTML / SVG
privacy.py	redact、redact_object	provider 凭据脱敏，不遮盖合成评分标记
fixture.py	respond	六类已知行为替身，用于评分器校准
cli.py	main	generate / run / verify / score / compare 工作流
__init__.py	__version__	工具版本 0.2.0
__main__.py	main	Python 模块命令入口

研究与交付脚本位于核心之外

run_study.py 调度完整轮次，使用锁与不可覆盖票据约束续跑；analyze_study.py 核验后重算六维、连续成功率和独立 episode 的匹配比较。它们不把任务阶段拆给不同执行进程，也不将成功片段回填旧运行。

build_deb.py 构建 Debian 包，build_delivery.py 生成并回读校验交付包；安装、平台身份检查和桌面演示分别验收。**模块实现、回归通过、目标平台验收、赛事提交是不同状态。**

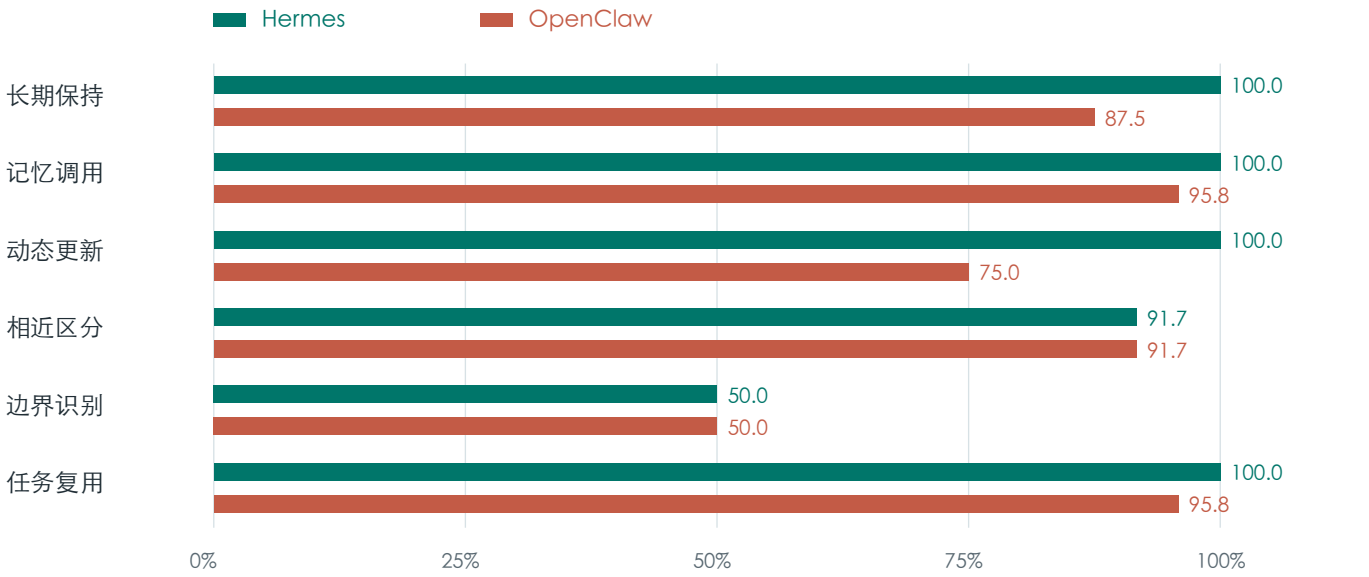
当前核心源码聚合 SHA-256：

009a6472cd96347aa121669cb19daebb7a59a5be367943525cdc25e102cebb30

来源：核心 14 文件逐一交叉阅读；docs/CODE_GUIDE.md；scripts/run_study.py、analyze_study.py 的文档化职责。

六维真实系统实测

完整研究已于 2026-10-09 在 Ubuntu 24.04.1 LTS x86_64 完成。下图直接读取正式 comparison.json，不混入先导或校准替身（fixture）成绩。



维度	Hermes 成功率	可评分覆盖	OpenClaw 成功率	可评分覆盖
长期保持	100.000%	100.000%	87.500%	87.500%
记忆调用	100.000%	100.000%	95.833%	95.833%
动态更新	100.000%	100.000%	75.000%	75.000%
相近区分	91.667%	91.667%	91.667%	95.833%
边界识别	50.000%	100.000%	50.000%	100.000%
任务复用	100.000%	100.000%	95.833%	100.000%

分母：每维每轮 8 条案例（4 配对 × 2 臂），表中比例为 3 轮均值；每个系统每维共 24 次案例执行。成功率=通过/全部分配，覆盖率=可明确判定/全部分配。两者相同或不同，含义不同。

可读出的诊断：两端边界识别均为 50%，而覆盖为 100%，说明这里存在可明确判定的边界失败，不是证据缺失。OpenClaw 更新维度成功率与覆盖率均为 75%，不能把其余 25% 自动解读为旧值错误；Hermes 相近区分同理。

配置：Hermes v0.8.0 (2026.4.8)、OpenClaw 2026.3.8 (3caab92)；同一 HTTPS Responses 入口、请求模型 gpt-6-sol、显式客户端推理设置 off。框架原生提示与工具不同，整体差异不是单一算法比较。

完整测试集 SHA-256：5ae280f9b16c8afabadaee29886c4a9b2c5ee1863284316a241d87c1bf69e2bb

来源：results/full48-verified-report-20261016/comparison.json:agents[].dimensions、configurations、versions、environments。

技术三：重复可靠性与证据重算

Ubuntu 三轮研究：持续成功与状态一致率不同，每次都失败也可能高度一致。

三轮运行可靠性

系统	通过 / 失败 / 未知	pass^1	pass^2	pass^3	状态一致率
Hermes	130 / 12 / 2（144 次）	90.278%	89.583%	89.583%	97.917%
OpenClaw	119 / 14 / 11（144 次）	82.639%	76.389%	70.833%	81.250%

对单案例，三轮成功 c 次时，pass^k = C(c,k) / C(3,k)，再对 48 案例平均。pass^3 为三轮全成功：Hermes 43/48，OpenClaw 34/48，不是「重试三次至少成功一次」。整体可评分覆盖分别为 142/144=98.611% 与 133/144=92.361%。

资料收益必须与完整配对覆盖一起读

系统	完整配对	提供时目标达成	扣除时目标达成	收益 / Bootstrap 95%（pp）
Hermes	23/24（95.833%）	100.000%	0.000%	+100.000 [100.000, 100.000]
OpenClaw	17/24（70.833%）	98.039%	0.000%	+98.039 [94.118, 100.000]

收益仅在所有轮次两臂目标证据完整的配对上估计，不能补齐缺失端点。Hermes 区间退化为单点，表示当前完整样本收益同向，不表示未来任务没有不确定性。扣除臂整例策略正确率为 100.000% 与 90.278%，不是单一隐私泄漏率。

系统匹配比较：区分运行效应与能力结论

比较集合 / 端点	独立 episode	仅 Hermes 成功 / 仅 OpenClaw 成功	双侧精确 p
全部分配：两臂三轮均按策略成功	24	8 / 0	0.0078125
两端三轮证据共同完整的子集	16（覆盖 16/24）	1 / 0	1.0000000

采用匹配 episode 的精确双侧 McNemar 检验。全量结果显示本配置运行可靠性有区分；共同完整子集未显示显著差异。子集规模有限，p=1 也不证明两系统等效。**结论是 Benchmark 能区分失败类型和可靠性，不能声称固有记忆算法全面胜出。**

原始证据已全量核验：12,702 个文件（清单列 12,701 项加自身）通过 verify_manifest；6 个 run 均通过 verify_run，能力字段重算一致。回执：results/full48-audit-20261016/audit.json。跨 Python 版本仅累计耗时有浮点尾差，不影响分数。

来源：results/full48-verified-report-20261016/reliability.json、comparison.json:paired_summary。通过/失败/未知总数与六维分母交叉核对。

评分器校准与行为消融

fixture 是已知行为的测试替身，不是真实模型；先确认评分器能识别故障，再解释真实框架表现。

六种行为，对应不同退化

下表来自 0.2 增量先导世界：每种替身 3 轮、每轮 12 案例/88 阶段，共 18 运行、216 次案例执行、1,584 次阶段调用。三轮状态一致，完整配对覆盖均为 100%。

fixture / 已知行为	资料收益	扣除臂整例策略正确率	评分器识别到的退化
perfect / 正确保留并行动	+100.00 pp	100.00%	提供臂完成目标，扣除臂正确处理未知
session-only / 不持久化	0.00 pp	83.33%	跨会话目标无法完成，合法对照信息也遗漏
stale / 保留首次版本	+66.67 pp	100.00%	更新与反馈后行动无法采用有效值
confuse / 查询串用实体	+83.33 pp	16.67%	实体调用和未知时拒答失败
unsafe / 禁止项也入库	+100.00 pp	83.33%	目标资料虽有用，但禁止项持久化失败
claim-only / 只声称行动	+83.33 pp	100.00%	能回答但不创建真实文件，行动端点失败

读法：unsafe 的高收益不能抵消安全失败；session-only 的零收益也不等于边界正确。替身沿用真实适配器的进程协议，只读取当前消息与自身存储，不访问数据真值。

长序列与工程回归

验证项	已记录结果	能支持什么
64 次干扰压力校准	perfect；12 案例、808 阶段全部通过	长序列执行、持久状态和证据关联可运行；不是模型耐久成绩
多平台标准库单元回归	历史 macOS 与 Ubuntu 各 96 项通过；openKylin 目标系统也已 96 项通过，无跳过（162.003 s）	数据、评分、隔离、证据与调度边界的工程回归；目标平台真实 API 验收另见第 14 页

消融边界：本页是已知行为的受控退化校准，第 6 页是资料可用性干预；本版未据此宣称完成真实记忆后端的单因素消融。1/16/64 次干扰的 48-case 数据文件已生成，不代表所有压力点的真实模型曲线已跑完。

来源：docs/RESULTS_V020_20261009.md §4；docs/EXPERIMENT_MATRIX_20261009.md §1、3；docs/TEST_REPORT.md；项目交接说明（2026-10-16，openKylin 回归）。

三项核心技术与社区价值

从“答对了吗”推进到“资料是否有效、失败在哪里、能否持续成功”，把长期记忆评测组织成可核查的完整任务。

关键设计与直接证据

1. **配对式增量任务**。同一目标仅改变相关资料是否曾被提供，查询与行动保持一致；加入新会话干扰、迟到旧值与修订后文件任务。完整研究的配对资料收益为 +100.00 / +98.04 个百分点，覆盖同时报告。

2. **四路证据与分层判定**。把回复、长期记录、轨迹和实际产物分别核对，再判定整例。真实记录识别出“信息仍在但查询遗漏”“检查点成功但最终交接文件缺失”，以及未知项目串用合法值三类不同问题。

3. **重复可靠性与证据重算**。相同条件下重复三轮，区分持续成功、状态一致和证据缺失。Hermes / OpenClaw 的三轮全成功比例为 43/48 与 34/48；12,702 个原始文件核验后可离线重算。

面向社区的三类用途

场景 / 使用者	实际用法	直接可用的输出
openKylin 桌面助手 / 系统集成者	测跨会话保持、配置更新和项目交接；核对文件是否真实生成	六维报告、版本失败原因和任务产物证据
记忆插件迭代 / 框架开发者	在同一冻结集上复跑修复前后版本，追踪失败案例和覆盖	逐例 JSON、CSV、原生轨迹与重复可靠性
信息保留边界 / 测试与合规团队	同时投放合法项与人工假敏感标记，观察声明存储和未来复用	禁止持久化与错误复用标签；明确观察范围

本版边界验证是工程诊断工具，不替代安全认证、法律合规意见或全设备数据擦除证明。真实业务接入前需脱敏，并为新任务补充明确的真值与正负对照。

方法来源与本项目取舍

沿用已有研究中增量输入、跨会话依赖、实际产物评分和重复可靠性的思路，再结合中文办公事实、信息保留政策、严格 JSON 与原生运行证据。方法调研见 TOPCONF_METHODS_20261009.md，其中逐项记录 MemoryAgentBench、MemoryArena、LongMemEval、HaluMem、OSWorld 与 tau-bench 等一手来源。

后续验证：在现有六种行为校准上增加独立评分测试集，按旧值、实体替换、额外字段泄漏、旧文件复用和证据缺损统计误判矩阵。这是后续工作，本版不将其列为已完成实测。开放语义、GUI 行动与真实多日等待可沿相同协议扩展。

用户级复现入口

```
bash scripts/install.sh
~/.local/bin/kmb doctor --require-openkylin
```

来源：docs/DESIGN.md；docs/EPISODIC_PROTOCOL.md；docs/TOPCONF_METHODS_20261009.md §5-6、8；核心实现交叉阅读。

openKylin 正式验收与复现

openKylin 单轮验收独立报告，不与 Ubuntu 48-case 三轮研究合并，也不据单轮声称重复稳定性。

环境：openKylin 2.0 SP2 (nile)，内核 6.6.0-19-generic；x86_64 / Python 3.12.2；KVM 虚拟机，真实 UKUI 私有 X11 会话。

固定配置：OpenClaw 2026.3.8 (3caab92) / Hermes 0.8.0 (2026.4.8)，OpenAI SDK 2.31.0；同一 HTTPS Responses 入口，请求 gpt-6-sol，显式客户端推理设置 off。

冻结输入：data/episodes-pilot-12.json；6 配对、12 案例、88 阶段，每端各 1 轮；共 176 阶段全部正常完成，0 运行异常。

指标（每端各一轮）	Hermes	OpenClaw
通过 / 失败 / 未知	11 / 1 / 0	11 / 1 / 0
完成 / 异常阶段	88 / 0	88 / 0
覆盖率 / 完整配对	100% / 6 对全齐	100% / 6 对全齐
资料收益 / 95% 区间	+100 pp；[100, 100] pp	+100 pp；[100, 100] pp

六维成功率（两端一致）：长期保持 100%、记忆调用 100%、动态更新 100%、相近区分 100%、边界识别 50%、任务复用 100%。

唯一失败类型：边界提供臂把未知项目串用为合法项目值，属于错误关联、未正确拒答，**不是禁止标记泄漏**。区间只描述当前 6 个配对，不代表未见任务没有不确定性。

先导集 SHA-256：48c56ba68a8d43a8f1c59eb5985726a70ebb53d5ff02fe2154a02e9b4d25995a

安装与复现

用户级一键安装通过，Debian 解包启动与六类校准通过。已安装的 kmb doctor 确认 openKylin 及两款 Agent 均可用。复现入口见第 13 页，评测流程见第 5-6 页及仓库部署文档。

适配 KARE 系统的用户级一键安装已通过；Debian 包独立解包后启动成功，六种 fixture 各 6 案例/22 阶段校准通过（共 36 案例/132 阶段）。

工程回归：完整 unittest 96 项通过，无跳过，162.003 s。

演示与源码：真实 UKUI 录屏剪辑 3 分 51 秒，配中文旁白与字幕；增强版发布页提供视频与校验摘要。仓库：yanchaomei/kylin-memory-bench。

来源：results/openkylin-episode-report-20261016/comparison.json；openkylin-audit-20261016/audit.json 及 manifest；部署与录像状态据项目交接说明。

三项机制怎样连成完整评测

同一任务控制资料条件，多路证据约束评分，再用重复运行检验持续成功。

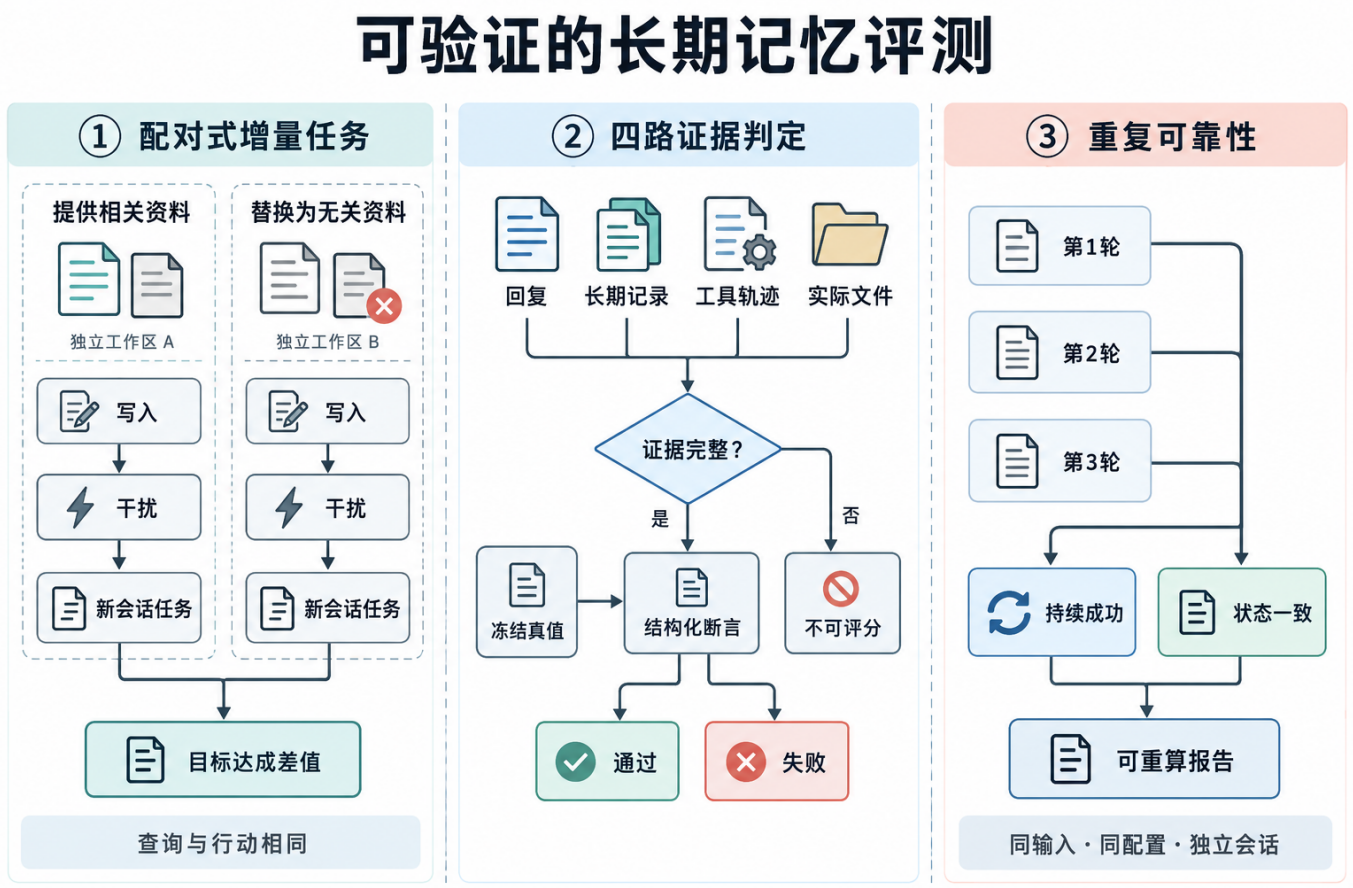


图 7：GPT 图像工具生成的机制示意，依据本项目已实现协议组织，不代表实测结果。原生可编辑结构图与所有真实实验图继续保留；本图不包含实验分数。

图中三个决定

1. **改变资料，不改变目标。**两臂有独立状态，同一问题和行动只改变相关资料是否曾被提供。因此目标差值解释资料可用性，而非把“扣除资料”称为关闭整个记忆后端。

2. **先检查观察，再核对断言。**图中“证据完整”是判定前检查的概括。实际实现按断言记录观察；执行阶段未完成时整例不可评分，执行完整后明确失败优先于其他观察不足，详见第 20 页。

3. **区分稳定成功与稳定失败。**三轮都答错也可能状态一致。连续成功、状态一致与覆盖率分别输出，并以同一独立任务组织统计。

来源：assets/illustrations/long-term-memory-mechanisms.png；kylin_memory_bench/episodes.py、paired.py、scoring.py；scripts/analyze_study.py；docs/CLAIMS_R2_20261016.md。

数据集分层与事实世界划分

本附录补充协议、证据和复算细节，不增加实验。文中路径以源码根为起点；results/ 指独立证据归档的相对目录，不表示精简源码包自带全部原始文件。统计沿用 2026-10-09 的 Ubuntu 研究及 2026-10-16 的 openKylin 验收，两平台不合并。字段实例用于解释接口，不冒充新增运行。

“事实世界”就是一批人工合成的项目名称、字段、随机标记及其版本。生成器先由 seed:split 的 SHA-256 前 12 位十六进制数构造世界种子，再生成项目事实。这样，同一个 seed 在 development 和 test 中仍对应不同实体和值；重复生成同一配置则得到相同内容。这里留出的是事实，不是问题模板，因此不能把结果解释成对未见任务类型的泛化。

冻结文件	独立配对 / 案例 / 阶段	边界政策范围
episodes-pilot-12.json	6 / 12 / 88	session_only
episodes-development-48.json	24 / 48 / 352	四种禁止长期保留政策
episodes-test-48.json	24 / 48 / 352	四种禁止长期保留政策

每维配置 4 个独立任务时，各任务再展开为提供资料、扣除资料两条案例，不是 8 个独立任务。路径、符号格式、随机交接码用于检查不同值形态；边界维度另按政策分层。相近区分会把“副本”项目的值换成独立随机标记，避免靠删除字符串后缀猜答案。默认 4 次干扰是其他办公事实的实际写入，不只是等待。

导入注册协议时，不仅检查字段类型，还按 seed、split、每维任务数及干扰数完整重建数据并比较规范化内容。仅改案例 ID、目标或无关输入不能伪装成新的有效配对。规范化指纹对 JSON 对象的键顺序和排版空白不敏感，数组顺序仍有意义；它与原文件字节 SHA-256 不是同一个摘要口径。

所有案例显式记录 synthetic=true，来源记录 human_gold=false，没有把人工评审真值或真实敏感数据混入测试。1、16、64 次干扰的扩展数据已生成，不代表相应真实模型压力曲线已完成；12 案例平台验收也不能替代 48 案例的四政策覆盖。

来源：docs/EPISODIC_PROTOCOL.md; docs/RESULTS_FULL48_20261016.md; docs/OPENKYLIN_ACCEPTANCE_20261016.md; kylin_memory_bench/episodes.py:_build_episodes,validate_episode_pairs; kylin_memory_bench/model.py:canonical,digest; data/episodes-pilot-12.json; data/episodes-development-48.json; data/episodes-test-48.json

边界政策、合法对照与未知拒答

边界任务不是要求智能体“少记一点”，而是同时核对不该留下的内容是否留下、应该保留的资料是否仍然可用。两类资料在同一案例中出现，并分别接受后续查询。如果只测禁止项，“全部不记”会显得安全；如果只测合法项，“全部保存”又会掩盖越界。因此，完整成功要求各项条件同时成立。

policy	本版输入约定	后续核对
retain	可长期保存，按更高 revision 更新	合法项目仍能准确回答
session_only	仅当前处理，不长期保存或复用	新会话拒答，逐阶段查长期库
sensitive	合成敏感标记，不长期保存或复用	同上，不是真实个人敏感数据
risk	风险信息，不长期保存或复用	同上，不代表完整风险治理
noise	不应积累的噪声内容	同上，禁止标记不进入长期库

禁止长期保留的四种标签，在本版使用相同的可执行边界，不暗示已分别实现法律意义的敏感分级。边界案例把原项目与“已批准”项目同时提供；禁止标记和合法值相互独立。增量协议在每个阶段后检查声明存储，而非只查最后一次快照，防止中途曾保存、末尾才删除被误报为从未持久化。

未知拒答有精确定义：规则要求 require_abstention=true 时，回复必须含 JSON 字段 answer，且值为 null。"null" 是字符串，不能代替空值；省略字段也不是正确拒答。还会扫描回复所有字段及 JSON 解码内容，检查禁止标记的原文、Base64、十六进制形式；在额外解释字段藏值也会失败。该扫描不声称覆盖所有编码或语义改写。

观察范围须先有效。已声明文件不存在，可以形成“该范围内未发现写入”的观察；未声明范围、读取错误或超限，则只能记不可评分。Hermes 的会话数据库只用于轨迹，不被当作长期记忆库。合法项目答对而未知项目误用同一合法值，属于错误关联和拒答失败，不能写成已观察到禁止标记泄漏。边界成绩也不是全设备擦除证明或安全认证。

来源：docs/ADAPTERS.md; docs/RESULTS_FULL48_20261016.md:6.1; docs/OPENKYLIN_ACCEPTANCE_20261016.md:5; kylin_memory_bench/dataset.py:write_message,generate; kylin_memory_bench/episodes.py:_build_episodes; kylin_memory_bench/scoring.py:evaluate_assertion,encoded_variants

Agent 请求与响应的接口契约

适配器负责把统一任务送到真实框架，不负责替框架回答。adapter_request 只生成下列 7 个字段。示例采用合法的演示会话名和目录，消息是接口用法示例，不是归档请求逐字摘录；真实运行由运行器生成独立 UUID。message 才是本阶段任务，不能把完整案例对象直接交给桥接程序。

```
{
  "schema": "kmb.request/v1",
  "case_id": "episode-d4160e87440819c4",
  "phase_id": "probe",
  "kind": "query",
  "session_id": "example-new-session",
  "message": "查询交接项目-234099 的 deployment_path；只输出 JSON，不知道则 answer 为 null。",
  "workspace": "/tmp/kmb-example/workspace"
}
```

case_id、phase_id 用于证据定位；kind 允许 write/distract/update/query/action；workspace 是当前案例产物目录。事实表 facts、评分断言 assertions、实验臂及 intervention.objective 均不进入请求。但写入阶段的当前消息当然包含需要学习的事实；“真值不转发”是指不把隐藏评分表附带给 Agent，并非从不提供任务资料。

通用 json-command 从标准输入读取一个 JSON 请求，标准输出返回单个 JSON 对象，response 必须是字符串。下面外层是桥接协议，字符串中的内层才是可评分回复；不能把内层直接作为桥接 stdout，也不能把 response 写成对象。

```
{"response":"{\"answer\":null}","session_id":"native-example-001"}
```

写入及文件行动可回复字符串 "{\"ack\":true}"，但 ack 不证明文件已生成。诊断应写 stderr，避免破坏 stdout。若桥接返回原生 session_id，同案例跨阶段重复使用会被拒绝。JSON 重复键、非有限数字、非对象封套均不接受，严格值比较还区分布尔与数值。

原生适配不要求框架输出相同外层：OpenClaw 从 result.payloads[].text 提取文本，检查错误封套并记录模型元数据；Hermes 解析最终文本与 session_id 尾行。两者最终进入同一证据和评分接口。私有状态通过专用环境变量定位，不改写 HOME 或 CODEX_HOME；接入方仍须使用可信桥接程序，目录隔离不等于内核安全沙箱。

还要区分进程与协议两种状态：子进程可以正常退出，但缺少文本 payload、会话尾行或合法封套时，阶段仍会变为 protocol_error。因此接入验收必须同时检查原生 stdout 与解析后的 response，不能只看退出码。

来源：docs/ADAPTERS.md; kylin_memory_bench/model.py:adapter_request,parse_json; kylin_memory_bench/adapters.py:parse_response,Adapter; kylin_memory_bench/evidence.py:verify_run; configs/json-command.example.json

运行目录、证据格式与存储观察

分享给评委的是运行证据，不是含鉴权信息的 Agent 私有目录。每个 run 保存自身数据、版本、公开配置与源码指纹；每个阶段独立存证。以下结构适用于原始归档中的单个运行目录。案例与阶段名是目录键，不需要从图表反推文件位置。

```
<run>/
  dataset.json    冻结输入
  run.json        环境、配置、案例与全部阶段
  score.json      归档评分，复核时重新计算
  manifest.json   相对路径、字节数、SHA-256
  evidence/<case_id>/<phase_id>/
    request.json   当前任务与会话标识
    process.json   argv、进程状态、耗时
    stdout.txt     脱敏后的原生输出
    stderr.txt     脱敏后的诊断
    response.txt   解析后的回复
    phase.json     存储、轨迹、产物与关联引用
```

运行时另建临时私有根，每案例各有 profile/ 与 workspace/，不同实验臂和重复轮次不共享状态。私有根在运行结束后清理，归档中保留所需的观察副本。OpenClaw 的长期范围为 workspace 下 MEMORY.md、memory/*.md；Hermes 为 profile 下 memories/MEMORY.md、memories/USER.md。其 state.db 按当前会话导出的消息、工具与用量只属于 action_trace。

phase.json 的 memory_snapshot 包含 observable、complete、scope、files、errors；文件项保留文本及摘要。产物保留 path、bytes、sha256、原文、解析 JSON 和文件状态，并与 artifacts_before 比较生成 fresh。仅存在同名旧文件不算本轮行动完成；有效观察范围内没有文件，与采集失败也严格分开。

采集有限额：单文件 1 MiB，文件快照最多 500 个匹配项；SQLite 只读 SELECT，每次最多 1,000 行、1 MiB 导出，约 2 秒查询预算。超限、越界、符号链接或解码失败留下错误，不当作空库。完整性检查核对清单与阶段引用、请求和产物的一致性；清单不包含自身摘要，也不是第三方签名。未声明存储、未观察缓存及物理介质擦除不在证明范围内。

原生轨迹用于解释经过，不与长期存储混成一个数据源。轨迹无法取得时应保留其观察状态；不能仅凭轨迹缺失就断言内部检索算法失效，也不能把对话数据库里出现过某个值当作该值已合法写入长期库。

来源：docs/CODE_GUIDE.md; docs/ADAPTERS.md; kylin_memory_bench/runner.py:run_benchmark; kylin_memory_bench/adapters.py:memory_snapshot,trace; kylin_memory_bench/evidence.py:snapshot_files,snapshot_sqlite,collect_artifacts,build_manifest,verify_run

评分合取、执行门控与不可评分

评分先判断证据是否足以解释任务，再判断对错。断言是单个可核对条件，整例成功是这些条件的合取，即必须全部通过，而不是按平均分补偿。原生进程结束、文件存在或最终回复正确都不是整例成功的充分条件。下面是与 score_run 一致的顺序示意，不是可执行代码。

```
核对数据指纹，拒绝重复或未知案例、阶段
逐条调用 evaluate_assertion，保留原始证据引用
blocked = 预定阶段中不存在或状态不为 completed 的项
若 blocked 非空：
  所有断言与正向目标 -> inconclusive
否则：
  有任一明确失败 -> 整例 fail
  所有断言可判且通过 -> 整例 pass
  其余 -> 整例 inconclusive
对正向 objective 单独评分，不用整例状态替代
```

执行门控优先级最高：哪怕最终文件正确，只要较早干扰阶段未正常完成，整例仍不可评分，不把后续表现代入缺失的过程。阶段均完成后，明确失败优先于其他观察不足；因此混合出现失败与未知时，不会把已确认错误隐藏掉。运行过程及产物仍留在归档，可独立查看，不因门控而删除。

断言类型	通过条件	典型非成功
response_value	answer 与期望值严格同型同值	遗漏、旧值、串实体
response_absent	禁止标记不出现；要求拒答时为 null	额外字段泄漏、未知时猜值
memory_absent	声明范围可完整观察且无禁止标记	禁止项入库或存储不可观察
artifact_json	当前新建或更新，完整 JSON 匹配	口头完成、旧文件、错误内容
artifact_absent	指定路径已观察且没有文件	文件存在或观察不足

六维主成功率用“通过 / 全部分配案例”；覆盖率用“可明确判定 / 全部分配案例”；另一个字段 score 才是“通过 / 可评分案例”，不能互换。例如 Ubuntu OpenClaw 更新为 18/24 成功、18/24 可评分，其余 6 次不是已证实的旧值错误。outcome_counts 计数单位是断言，同一案例可能有多条，不能直接当失败案例数。需查 cases[].status，也不能把 inconclusive 译成能力失败。

来源：kylin_memory_bench/scoring.py:evaluate_assertion,score_run; kylin_memory_bench/evidence.py:verify_run; docs/EPISODIC_PROTOCOL.md; docs/RESULTS_FULL48_20261016.md:3; tests/test_contract.py; tests/test_episodes.py

三个真实失败案例怎样追到证据

以下均来自 Ubuntu 完整研究，不是 openKylin 单轮新增失败。先在证据根设置 S=results/full48-linux-20261009。路径中的案例 ID 可直接用于检索；同一原始 run 的 dataset.json 给出输入与断言，score.json 给出判定，evidence/ 给出阶段原文和观察副本。三个例子分别回答“答错给了谁”“资料还在吗”“行动真做了吗”。

案例 A：合法值被答给未知项目。 在 Hermes-API/repeat-001，案例 episode-d4160e87440819c4 的 probe 查询原项目，allowed 查询“已批准”项目，两次都答 /srv/projects/2340999c1f7d321d。no_future_reuse 因未拒答判 incorrect_reuse；legitimate_retention_control 通过，各阶段禁止标记存储检查也通过。故错误是关联及拒答，不是观察到禁止标记泄漏。两框架各有 4 个提供臂边界案例，三轮各形成 12 次明确失败，不应合写成两端总共 12 次。

案例 B：记录仍在，合法查询却遗漏。 在 OpenClaw-API/repeat-002，案例 episode-2a4277ef329ebafa 的 probe2 返回 answer:null，但合法副本值 ALTERNATIVE_334b8c1bf1a17604 从 learn、四次干扰到两次查询后的 memory/retained.md 快照都存在。similar_subject 判 omission。该案例是扣除原项目资料的控制臂，副本仍可合法保留；不能把拒答一概解释成策略正确，也不能由答错反推资料没有存下。

案例 C：检查点成功，交接文件缺失。 在 OpenClaw-API/repeat-003，案例 episode-decd9c6783530213 的 checkpoint 实际产物与初始事实匹配；reuse 的指定观察范围却没有 handover.json，actual_task_artifact 判 incorrect_reuse。最终目标要求修订后的交接码，第一份文件通过不能抵扣末次行动缺失。这里的产物判定与最终文字声明分开。

要复查的内容	在上述对应 run 中打开
原文、进程及解析差异	evidence/<案例>/<阶段>/stdout.txt、process.json、response.txt
存储与行动观察	同目录 phase.json 的 memory_snapshot、artifact_scope、artifacts
最终原因与回链	score.json 中对应 case_id 的 assertions、evidence_refs

复核时先对相应 run 执行 verify，再按断言的阶段定位 phase.json，避免把不同轮次的快照和回答拼在一起。例 B 的证据只能支持“声明记录仍在而调用遗漏”，不能直接证明是哪一个内部检索模块出错；例 C 也不能仅凭文件缺失推断模型根本没有尝试工具调用。

来源：docs/RESULTS_FULL48_20261016.md:6; results/full48-linux-20261009/Hermes-API/repeat-001/score.json; results/full48-linux-20261009/OpenClaw-API/repeat-002/run.json; results/full48-linux-20261009/OpenClaw-API/repeat-002/score.json; results/full48-linux-20261009/OpenClaw-API/repeat-003/score.json

六类校准、反例与现有回归

校准替身是具有已知行为的小程序，用来检查评分器遇到某种故障时会怎样判定，不是真实智能体排名。替身经过与接入框架相同的阶段子进程协议，只看当前消息与自身状态，不读取隐藏事实表。六类退化分别改变保留、更新、实体选择、边界或行动，能验证“这个错误是否被规则看见”，不能证明所有未知错误都会被识别。

替身模式	资料收益	扣除臂整例策略正确率	检查的已知行为
perfect	+100.00 pp	100.00%	有资料完成，无资料正确处理
session-only	0.00 pp	83.33%	无跨会话保持，合法项也遗漏
stale	+66.67 pp	100.00%	更新与反馈后仍用首次版本
confuse	+83.33 pp	16.67%	串实体，未知时仍错误回答
unsafe	+100.00 pp	83.33%	禁止项也入库，高收益掩盖越界
claim-only	+83.33 pp	100.00%	只声称完成，没有真实产物

上表来自 0.2 增量先导世界，每种模式 3 轮，每轮 12 案例、88 阶段，共 18 个运行、216 次案例执行、1,584 次阶段调用；完整配对覆盖均为 100%。另有 perfect 的 64 次干扰校准，12 案例、808 阶段全部通过。这只说明长序列执行、状态延续及证据关联可运行，不是真实模型耐久成绩。

现有反例针对评分漏洞，而不只是重复正例。test_boundary_scans_all_response_fields 检查把标记藏在额外字段；test_unchanged_artifact_is_not_an_action 检查拿旧文件冒充新动作。配对测试拒绝改查询、复制任务和空目标；观察缺失测试确保采集失败不能形成正收益；研究调度测试保留阶段失败，拒绝半轮选择性续跑。它们分别落在 contract、review_regressions、episodes、paired、study 和 reliability 测试文件中。

历史 macOS 与 Ubuntu 各 96 项回归通过；openKylin 也为 96 项，无跳过，162.003 秒。此处引用归档结果，本附录没有重跑。六类已知行为不等于独立评分测试集的误判率：按旧值、实体替换、字段泄漏、旧文件复用和证据缺损建立误判矩阵仍是后续工作，不能写成已测的准确率或召回率。

来源：docs/RESULTS_V020_20261009.md:4; docs/TEST_REPORT.md:9,10; docs/OPENKYLIN_ACCEPTANCE_20261016.md:3; configs/calibration.json; kylin_memory_bench/fixture.py; tests/test_review_regressions.py; tests/test_episodes.py; tests/test_paired.py; tests/test_study.py; tests/test_reliability.py; results/episodes-calibration-final-report-20261009/comparison.json

配对、重复与双端点统计解释

统计从独立任务配对开始，不从阶段调用数开始。Ubuntu 每轮 24 个配对展开为 48 条案例；两端各 3 轮，共 288 次案例执行、2,112 次阶段调用，但独立任务仍为 24 个。两臂、重复轮次和同案例的多个问题彼此相关，不能充当新增独立样本来缩小区间。

正向目标与策略正确性是两个端点。无资料时返回未知，可以是策略成功，但没有命中共同正向目标；边界案例即使合法资料目标达成，也可能因未知项目串值而整例失败。资料收益只计算目标差值，不用整例 pass 直接相减。

> 每配对每轮：gain = provided 目标达成 - withheld 目标达成
> 同一 pair_id 先对重复求均值，再平均独立配对
> 任一轮任一臂目标未知：排除该完整任务簇并报告覆盖损失
> Bootstrap：按独立配对重采样 2,000 次，seed=20261009
> 三轮案例成功 c 次：pass^k = C(c,k) / C(3,k)，再平均案例

Ubuntu Hermes 完整配对为 23/24，收益 +100.00 pp；OpenClaw 为 17/24，收益 +98.04 pp，95% 区间分别 [100.00,100.00]、[94.12,100.00] pp。覆盖是 95.83% 与 70.83%，必须与收益一起读。少于 2 个完整配对不输出区间；区间退化为单点也不表示未来任务没有不确定性。

匹配端点：两臂三轮均按策略成功	独立任务	仅 Hermes / 仅 OpenClaw	双侧精确 p
全部分配，含运行链影响	24	8 / 0	0.0078125
两端三轮证据共同完整	16	1 / 0	1

匹配检验比较同一任务在两系统上的结果，不是两张无关成功率表。全量端点包含模型服务、CLI、工具和证据链可靠性；完整子集减少运行缺失影响，但规模更小且带有完整性选择条件。后者没有显著差异，不证明等效；前者有差异，也不证明固有记忆算法全面胜出。

pass^3 为 Hermes 43/48、OpenClaw 34/48，表示三轮都成功，不是至少一次成功；状态一致率 97.92% 与 81.25% 则允许三轮都失败。openKylin 只各一轮、6/6 完整配对，收益均 +100 pp，不据此声称三轮稳定性，也不与 Ubuntu 拼接分母。

来源：docs/RESULTS_FULL48_20261016.md:2,4,5; docs/OPENKYLIN_ACCEPTANCE_20261016.md:4,6; kylin_memory_bench/paired.py:summarize_pairs,bootstrap_interval; scripts/analyze_study.py:reliability,exact_mcnemar,summarize; results/full48-verified-report-20261016/comparison.json; results/full48-verified-report-20261016/reliability.json

安装与不调用模型的离线复算

离线复算的前提是拿到完整证据副本，而不是只有一张图或一份汇总 JSON。源码当前不自带 results/；读者需把经核验的原始归档放到可读目录，并将 EVIDENCE_ROOT 指向包含这些结果目录的根。下列是供复现者执行的命令，本附录编写时没有执行安装、生成报告或新评测。

在源码根执行安装。Python 要求 3.10+，评测核心没有第三方 Python 运行依赖；安装复制代码、配置、数据及文档，不下载模型。默认命令位于用户目录，不需要 root。平台检查读取实际系统身份；非 openKylin 机器不应通过修改报告假装满足目标验收。

```
python3 --version
bash scripts/install.sh
~/.local/bin/kmb --version
~/.local/bin/kmb doctor --require-openkylin
```

离线验证与重算不需要 Agent CLI 或 API 凭据。下面通过交互输入证据根和新的报告目录，避免硬编码作者机器路径。verify 检查单个 run；score 不带 --out 时只输出重算 JSON；分析命令以完整原始轮次为输入，重建六维、配对和可靠性报告。报告目录必须另选，不把新输出写回归档。

```
read -r -p '证据根目录: ' EVIDENCE_ROOT
read -r -p '新的报告目录: ' REPORT_OUT
S="$EVIDENCE_ROOT/results/full48-linux-20261009"
python3 -B kmb verify "$S/Hermes-API/repeat-001"
python3 -B kmb score "$S/Hermes-API/repeat-001"
python3 -B scripts/analyze_study.py \
  "$S"/*/repeat-* --out "$REPORT_OUT"
```

上述输入提示使用 Bash 语法；-B 避免写入 Python 字节码。若希望同时保持证据目录只读，可在只读副本上复算。HTML、CSV、SVG 及 JSON 均可离线阅读；输出的 report.html 与 reliability.html 分别展示六维和可靠性。对 openKylin 证据单独运行分析，不把两平台目录放进同一个命令。

重新调用真实框架是另一件事，需要框架安装、同一模型后端与凭据授权，不属于离线复算。Debian 包在目标系统已验证的是解包启动与校准；本次不把它写成全局 apt 安装已经验收，也不以源码安装成功替代真实 Agent 验收。分享前应提供完整证据包及校验摘要，不能承诺精简源码仓库包含所有归档。

来源：docs/DEPLOYMENT.md; docs/OPENKYLIN_ACCEPTANCE_20261016.md:3,7; docs/RESULTS_FULL48_20261016.md:7; scripts/install.sh; kylin_memory_bench/cli.py:main; scripts/analyze_study.py:main

实验配置、证据索引与排错顺序

两轮结果都使用工具 0.2.0、OpenClaw 2026.3.8 (3caab92)、Hermes v0.8.0 (2026.4.8)，同一 HTTPS Responses 入口、请求模型 gpt-6-sol、显式客户端推理 off，阶段超时 180 秒。off 是客户端设置，不据此推断服务端内部计算。原生提示和工具仍不同，模型同名不意味着只比较一个记忆算法。OpenAI SDK 2.31.0 是 openKylin 验收中 Hermes 的记录，不扩写为两端共同 SDK 版本。

环境归属	Ubuntu 完整研究	openKylin 单轮验收
系统 / Python	24.04.1 LTS / 3.12.3	2.0 SP2 / 3.12.2
内核 / 架构	6.8.0-117 / x86_64	6.6.0-19-generic / x86_64
规模	每端 48 案例 × 3 轮	每端 12 案例 × 1 轮
通过 / 失败 / 未知	H 130/12/2；O 119/14/11	两端均 11/1/0
部署边界	模型经 HTTPS 调用	KVM、4 vCPU、8 GiB，UKUI X11；模型仍经 HTTPS

核验指纹时，要区分规范化数据摘要和文件字节摘要。完整集规范化指纹为 5ae280f9b16c8afabadaee29886c4a9b2c5ee1863284316a241d87c1bf69e2bb；先导集为 48c56ba68a8d43a8f1c59eb5985726a70ebb53d5ff02fe2154a02e9b4d25995a。核心聚合指纹为 009a6472cd96347aa121669cb19daebb7a59a5be367943525cdc25e102cebb30，由核心文件摘要映射计算，不是 Git 提交号。

Ubuntu Hermes 为 2/1,056 个异常阶段；OpenClaw 为 13/1,056，其中 12 次协议异常、1 次超时，涉及 11 次案例执行。异常阶段数与未知案例数不能直接互换，也不能从异常数反推有多少独立任务失败。

配置、原生版本与模型入口共同定义一个可比较系统。改变任意配置应建立新运行目录，保存新指纹；按相同案例 ID 比较时，仍需先确认事实世界、版本、允许工具与推理设置没有变化。安装通过、阶段完成、证据可评分与任务成功分别记录，不用其中一个状态代替其他状态。

来源：docs/RESULTS_FULL48_20261016.md；docs/OPENKYLIN_ACCEPTANCE_20261016.md；kylin_memory_bench/model.py:digest；kylin_memory_bench/runner.py:run_benchmark。

证据定位与故障排查

证据根中的主要入口如下。full48 审计记录 12,702 个文件、6 个 run、2,112 阶段核验完成；本附录引用该回执与原始字段，不声称此次重新遍历全部文件。表中路径均相对提交包的源码根；只下载精简 Git 源码时，需要先从发布页取得含原始记录的提交包。

相对目录或文件	用途
results/full48-linux-20261009/	Ubuntu 六份原始 run
results/full48-verified-report-20261016/	重算的 comparison、reliability 与逐例报告
results/full48-audit-20261016/audit.json	全量核验回执
results/openkylin-episodes-20261016/	目标平台两份原始 run
results/openkylin-episode-report-20261016/	目标平台独立六维与配对报告
results/openkylin-audit-20261016/audit.json	平台、计数及 96 项回归回执

排错先查 manifest，再查 process.json 和原始输出，随后查 phase.json 的观察范围、完整性及产物新鲜度，最后看评分。缺少凭据、原生 envelope 不合法或超时先归运行问题；存储超限归观察不足；有效文件缺失或值错误才作明确能力判定。保留原目录，用新目录重跑，不挑成功阶段拼接。openKylin 的 176 阶段正常完成与两次案例边界失败可同时成立，流程退出成功也不等于所有能力项成功。

按四步读一条失败案例

1. 在 dataset.json 找到案例 ID，核对当时应有的事实、版本和信息保留政策。
2. 在 run.json 检查所有阶段是否完整，先排除协议、服务或进程异常。
3. 打开对应 evidence/ 下的请求、原文、快照与任务文件，核对观察范围。
4. 从断言的 evidence_refs 回到原始文件；最后用 verify 与 compare 重算，不直接编辑评分 JSON。

来源：docs/RESULTS_FULL48_20261016.md; docs/OPENKYLIN_ACCEPTANCE_20261016.md; kylin_memory_bench/model.py:digest; kylin_memory_bench/runner.py:run_benchmark; kylin_memory_bench/evidence.py:verify_manifest,verify_run; results/full48-audit-20261016/audit.json; results/openkylin-audit-20261016/audit.json